TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
ĐẠI HỌC QUỐC GIA TP.HCM

# BÁO CÁO ĐỒ ÁN CUỐI KÌ

# XỬ LÝ SỐ LIỆU THỐNG KÊ

## ĐỀ TÀI: CDC Diabetes Health Indicators

**Giảng viên hướng dẫn:** T.S. Tô Đức Khánh

**Nhóm thực hiện:** Nhóm P

| | |
|---|---|
| Hoàng Võ Trí Bảo | MSSV: 22110022 |
| Ngô Thúy Quỳnh | MSSV: 22110184 |
| Nguyễn Đặng Hoàng Long | MSSV: 22110107 |
| Quách Vũ Luân | MSSV: 22110110 |
| Võ Thị Thu Hồng | MSSV: 22110066 |

TP. Hồ Chí Minh, tháng 1 năm 2026

# Mục lục


**1 Giới thiệu** **3**

1.1 Mục tiêu nghiên cứu . . . . . 3

1.2 Phương pháp và chiến lược phân tích . . . . . 3

**2 Mô tả và xử lí dữ liệu** **4**

2.1 Tổng quan về bộ dữ liệu . . . . . 4

2.2 Kiểm tra dữ liệu thiếu và cấu trúc dữ liệu . . . . . 6

**3 Khám phá dữ liệu** **6**

3.1 Phân bố biến mục tiêu . . . . . 6

3.2 Phân bố nhóm tuổi . . . . . 7

3.3 Phân bố biến BMI . . . . . 10

3.4 Phân bố biến HighBP và biến HighChol . . . . . 12

**4 Phân tích mối liên hệ và kiểm định.** **13**

4.1 Phân tích Thống kê Mô tả. . . . . 13

4.2 Kiểm định Giả thuyết Thống kê. . . . . 13

4.2.1 Kiểm định ANOVA một nhân tố. . . . . 13

4.2.2 Kiểm định Fisher–Pitman. . . . . 14

4.2.3 Permutation t-test với hiệu chỉnh Holm . . . . . 14

4.3 Phân tích tỷ lệ đái tháo đường theo nhóm tuổi và ước lượng bootstrap các yếu tố nguy cơ. . . . . 15

4.3.1 Phân tích tỷ lệ đái tháo đường theo nhóm tuổi. . . . . 15

4.3.2 Ước lượng bootstrap các yếu tố nguy cơ. . . . . 15

4.4 Kết quả phân tích thống kê . . . . . 16

4.4.1 Ước lượng tỷ lệ huyết áp cao bằng Bootstrap . . . . . 16

4.4.2 Mối liên hệ giữa Cholesterol cao và đái tháo đường . . . . . 16

4.4.3 Tình trạng hút thuốc và đái tháo đường . . . . . 17

4.4.4 Thống kê mô tả theo nhóm tình trạng đái tháo đường . . . . . 17

4.4.5 Tuổi và tỷ lệ đái tháo đường . . . . . 17

4.5 Nhận xét và kết luận . . . . . 17

**5 Hồi quy và tiên đoán.** **18**

5.1 Kết quả mô hình GLM (Logistic Regression) . . . . . 18

5.1.1 Phân bố biến phụ thuộc và cân bằng dữ liệu . . . . . 18

5.1.2 Kết quả ước lượng mô hình . . . . . 19

5.1.3 Đánh giá đa cộng tuyến bằng chỉ số VIF . . . . . 20

5.1.4 Tỷ số odds (Odds Ratio) . . . . . 21

5.1.5 Kết quả phân loại và tiên đoán . . . . . 21
5.1.6 Nhận xét . . . . . 22
5.2 Kết quả mô hình GAM (Generalized Additive Model) . . . . . 22
5.3 Kết quả ước lượng mô hình . . . . . 22
5.3.1 Diễn giải các hệ số tham số . . . . . 23
5.3.2 Đánh giá độ phù hợp của mô hình . . . . . 23
5.3.3 Minh họa trực quan các hiệu ứng . . . . . 24
5.3.4 Nhận xét . . . . . 24
5.4 Kết quả mô hình Logistic LASSO . . . . . 24
5.4.1 Lựa chọn tham số phạt . . . . . 24
5.4.2 Kết quả chọn lọc biến . . . . . 25
5.4.3 Đặc điểm của mô hình . . . . . 26
5.4.4 Đánh giá khả năng tiên đoán . . . . . 26
5.4.5 Nhận xét . . . . . 26

# 1 Giới thiệu

Bệnh tiểu đường là một trong những bệnh mạn tính phổ biến và có tốc độ gia tăng nhanh trên toàn cầu, gây ra nhiều biến chứng nghiêm trọng như bệnh tim mạch, đột quỵ, suy thận, mù lòa và làm giảm đáng kể chất lượng cuộc sống của người bệnh. Theo các nghiên cứu y học, tiểu đường có mối liên hệ chặt chẽ với nhiều yếu tố nguy cơ liên quan đến lối sống, tình trạng sức khỏe và đặc điểm nhân khẩu học như béo phì, tăng huyết áp, rối loạn cholesterol, mức độ hoạt động thể chất và độ tuổi.

Trong bối cảnh đó, việc phân tích dữ liệu y tế quy mô lớn nhằm khám phá các mối liên hệ giữa tình trạng tiểu đường và các yếu tố nguy cơ đóng vai trò quan trọng trong việc hỗ trợ công tác phòng ngừa, chẩn đoán sớm. Các bộ dữ liệu khảo sát sức khỏe cộng đồng, với số lượng quan sát lớn và nhiều biến đo lường liên quan đến sức khỏe, cung cấp nền tảng phù hợp cho việc áp dụng các phương pháp phân tích thống kê hiện đại.

Trong báo cáo này, nhóm sử dụng bộ dữ liệu *Diabetes Health Indicators* được trích xuất từ khảo sát *Behavioral Risk Factor Surveillance System (BRFSS)* năm 2015 do Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh Hoa Kỳ (CDC) thực hiện.

## 1.1 Mục tiêu nghiên cứu

Mục tiêu là phân tích và khám phá mối liên hệ giữa tình trạng tiểu đường và các yếu tố sức khỏe, lối sống trong cộng đồng, thông qua việc áp dụng các phương pháp phân tích thống kê đã học. Cụ thể, báo cáo tập trung vào các mục tiêu sau:

- Khám phá và mô tả đặc điểm phân bố của các biến sức khỏe chính trong bộ dữ liệu, bao gồm chỉ số khối cơ thể (BMI), tuổi, tăng huyết áp và cholesterol cao.
- Phân tích mối liên hệ giữa tình trạng tiểu đường và một số yếu tố nguy cơ quan trọng thông qua các phương pháp thống kê mô tả và kiểm định.
- Áp dụng các phương pháp thống kê suy luận và mô hình hóa nhằm đánh giá mức độ ảnh hưởng của các yếu tố nguy cơ đến khả năng mắc bệnh tiểu đường.

Thông qua quá trình phân tích, báo cáo hướng đến việc cung cấp cái nhìn tổng quan dựa trên dữ liệu về các yếu tố liên quan đến bệnh tiểu đường, đồng thời minh họa cách ứng dụng các phương pháp phân tích thống kê trong việc giải quyết một bài toán thực tế thuộc lĩnh vực y tế cộng đồng.

## 1.2 Phương pháp và chiến lược phân tích

Quá trình phân tích dữ liệu được thực hiện theo một quy trình gồm các bước chính, phù hợp với mục tiêu nghiên cứu và nội dung đã học trong học phần.

Đầu tiên, dữ liệu được kiểm tra và làm sạch nhằm đảm bảo tính nhất quán, bao gồm việc kiểm tra giá trị thiếu, phạm vi hợp lý của các biến và chuẩn hóa định dạng dữ liệu khi cần thiết. Các thống kê mô tả và bảng tần suất được sử dụng để tóm tắt đặc điểm ban đầu của dữ liệu, kết hợp với các biểu đồ mô tả nhằm trực quan hóa phân bố của các biến quan trọng. Đối với các biến liên tục, biểu đồ mật độ (kernel density) và phương pháp bootstrap được áp dụng để ước lượng khoảng tin cậy cho một số đại lượng thống kê tiêu biểu.

Tiếp theo, mối liên hệ giữa tình trạng tiểu đường và các yếu tố nguy cơ được phân tích thông qua các kiểm định thống kê phù hợp. Các kiểm định Chi-square và Fisher được sử dụng cho các biến phân loại, trong khi các phương pháp kiểm định dựa trên hoán vị và bootstrap được áp dụng nhằm tăng tính linh hoạt và giảm phụ thuộc vào giả định phân phối.

Trong trường hợp so sánh nhiều nhóm, phân tích phương sai một yếu tố được sử dụng, kết hợp với các phương pháp hiệu chỉnh như Holm và kiểm soát tỷ lệ phát hiện sai (FDR – Benjamini-Hochberg) để hạn chế sai số do so sánh nhiều lần.

Cuối cùng, các mô hình hồi quy và dự đoán được xây dựng nhằm đánh giá ảnh hưởng của các yếu tố nguy cơ đến khả năng mắc bệnh tiểu đường. Mô hình hồi quy logistic được sử dụng làm mô hình cơ sở, bên cạnh các phương pháp mở rộng như spline, GAM và kỹ thuật  hóa như LASSO. Hiệu quả của các mô hình được đánh giá và so sánh thông qua các chỉ số đánh giá phù hợp.

# 2 Mô tả và xử lí dữ liệu

## 2.1 Tổng quan về bộ dữ liệu

Bộ dữ liệu bao gồm 253,680 quan sát, tương ứng với các cá nhân trưởng thành tại Hoa Kỳ, cùng 22 biến phản ánh tình trạng sức khỏe, lối sống và đặc điểm nhân khẩu học.

Biến mục tiêu của bài toán là `Diabetes_012`, mô tả tình trạng bệnh tiểu đường của đối tượng khảo sát, với các mức: 0 – không mắc tiểu đường, 1 – tiền tiểu đường, 2 – tiểu đường.

Các biến còn lại được xem là các yếu tố liên quan hoặc yếu tố nguy cơ tiềm năng, bao gồm:

- `HighBP`: Tình trạng cao huyết áp (0: không, 1: có).
- `HighChol`: Tình trạng cholesterol cao (0: không, 1: có).
- `CholCheck`: Đã kiểm tra cholesterol trong vòng 5 năm gần nhất (0: không, 1: có).

- `BMI`: Chỉ số khối cơ thể (Body Mass Index), biến liên tục.
- `Smoker`: Đã từng hút ít nhất 100 điếu thuốc trong suốt cuộc đời (0: không, 1: có).
- `Stroke`: Đã từng bị đột quỵ (0: không, 1: có).
- `HeartDiseaseorAttack`: Tiền sử bệnh tim mạch vành hoặc nhồi máu cơ tim (0: không, 1: có).
- `PhysActivity`: Có tham gia hoạt động thể chất trong vòng 30 ngày gần nhất (không tính hoạt động liên quan đến công việc) (0: không, 1: có).
- `Sex`: Giới tính (0: nữ, 1: nam).
- `Age`: Nhóm tuổi, được phân thành 13 nhóm theo quy ước của BRFSS.
- `Education`: Trình độ học vấn cao nhất đã hoàn thành (theo các mức phân loại của BRFSS).
- `Income`: Mức thu nhập cá nhân (theo các nhóm thu nhập của BRFSS).
- `GenHlth`: Mức độ tự đánh giá sức khỏe chung (từ rất tốt đến rất kém).

```
## # A tibble: 253,680 × 22
##    Diabetes_012 HighBP HighChol CholCheck   BMI Smoker Stroke
##           <dbl>  <dbl>    <dbl>     <dbl> <dbl>  <dbl>  <dbl>
##  1            0      1        1         1    40      1      0
##  2            0      0        0         0    25      1      0
##  3            0      1        1         1    28      0      0
##  4            0      1        0         1    27      0      0
##  5            0      1        1         1    24      0      0
##  6            0      1        1         1    25      1      0
##  7            0      1        0         1    30      1      0
##  8            0      1        1         1    25      1      0
##  9            2      1        1         1    30      1      0
## 10            0      0        0         1    24      0      0
## # ℹ 253,670 more rows
## # ℹ 15 more variables: HeartDiseaseorAttack <dbl>, PhysActivity <dbl>,
## #   Fruits <dbl>, Veggies <dbl>, HvyAlcoholConsump <dbl>, AnyHealthcare <dbl>,
## #   NoDocbcCost <dbl>, GenHlth <dbl>, MentHlth <dbl>, PhysHlth <dbl>,
## #   DiffWalk <dbl>, Sex <dbl>, Age <dbl>, Education <dbl>, Income <dbl>
```

Hình 1: Minh họa cấu trúc dữ liệu khảo sát (10 dòng đầu)

Nhìn chung, bộ dữ liệu bao gồm cả biến liên tục và biến phân loại, phản ánh đa dạng các khía cạnh liên quan đến sức khỏe và lối sống, phù hợp cho việc áp dụng các phương pháp thống kê mô tả, kiểm định và mô hình hóa nhằm nghiên cứu các yếu tố liên quan đến bệnh tiểu đường.

### 2.2 Kiểm tra dữ liệu thiếu và cấu trúc dữ liệu

```
## # A tibble: 1 × 9
##     rows columns discrete_columns continuous_columns all_missing_columns
##    <int>   <int>            <int>              <int>               <int>
## 1 253680      22                0                 22                   0
## # ℹ 4 more variables: total_missing_values <int>, complete_rows <int>,
## #   total_observations <int>, memory_usage <dbl>
```

Hình 2: Kết quả kiểm tra cấu trúc dữ liệu và giá trị thiếu

Kết quả kiểm tra cho thấy bộ dữ liệu không chứa giá trị thiếu và tất cả các quan sát đều đầy đủ, với 22 biến được ghi nhận cho 253,680 cá thể.

## 3 Khám phá dữ liệu

Dựa trên các nghiên cứu trước đây về tiểu đường, bốn biến gồm độ tuổi (Age), chỉ số khối cơ thể (BMI), tình trạng cao huyết áp (HighBP) và cholesterol cao (HighChol) được lựa chọn để phân tích chi tiết. Đây là những yếu tố nguy cơ cốt lõi, phản ánh trực tiếp tình trạng chuyển hóa và có vai trò quan trọng trong chẩn đoán cũng như dự phòng bệnh tiểu đường.

### 3.1 Phân bố biến mục tiêu

```
## # A tibble: 3 × 3
##   Diabetes_012      n   prop
##          <dbl>  <int>  <dbl>
## 1            0 213703 0.842
## 2            1   4631 0.0183
## 3            2  35346 0.139
```

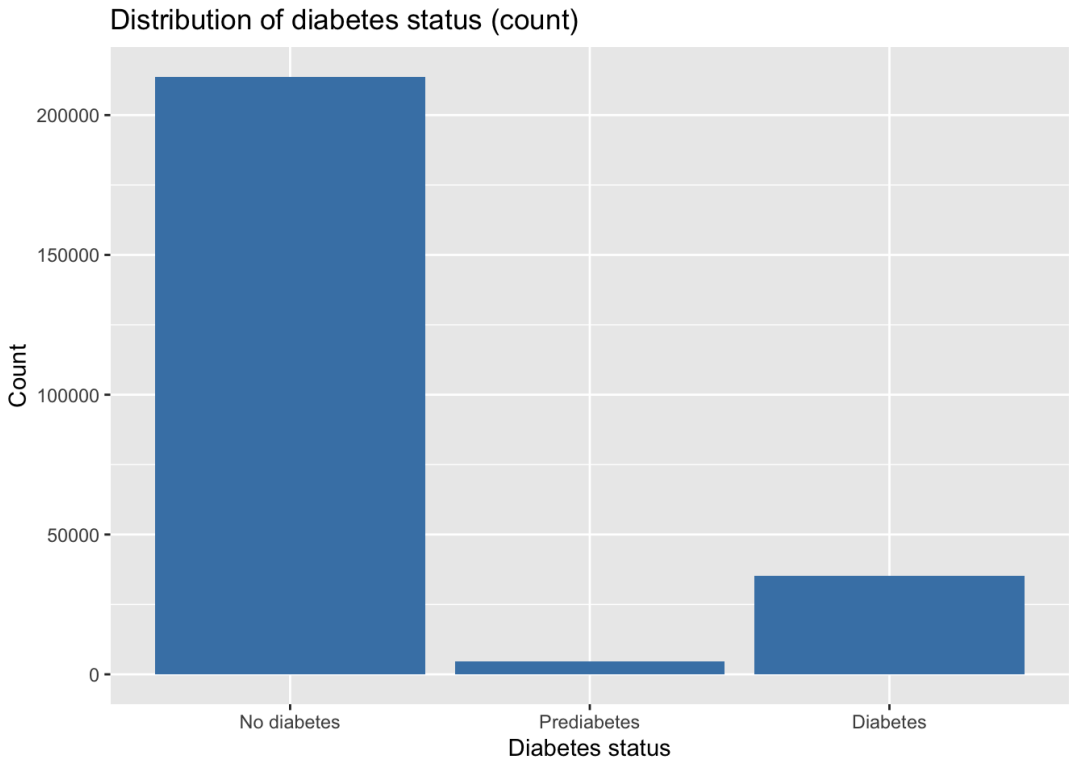


Hình 3: Phân bố biến mục tiêu

Hình cho thấy phân bố của biến mục tiêu `Diabetes_012` mất cân bằng rõ rệt. Phần lớn đối tượng thuộc nhóm *không mắc tiểu đường* (khoảng 84.2%), trong khi nhóm *tiền tiểu đường* chiếm tỷ lệ rất nhỏ (khoảng 1.8%) và nhóm *tiểu đường* chiếm khoảng 13.9%.

Sự mất cân bằng này cần được lưu ý trong các bước phân tích và mô hình hóa tiếp theo, đặc biệt khi thực hiện kiểm định thống kê và xây dựng mô hình dự đoán.

### 3.2 Phân bố nhóm tuổi

```
##
## 18–24 25–29 30–34 35–39 40–44 45–49 50–54 55–59 60–64 65–69 70–74 75–79   80+
##  5700  7598 11123 13823 16157 19819 26314 30832 33244 32194 23533 15980 17363
```

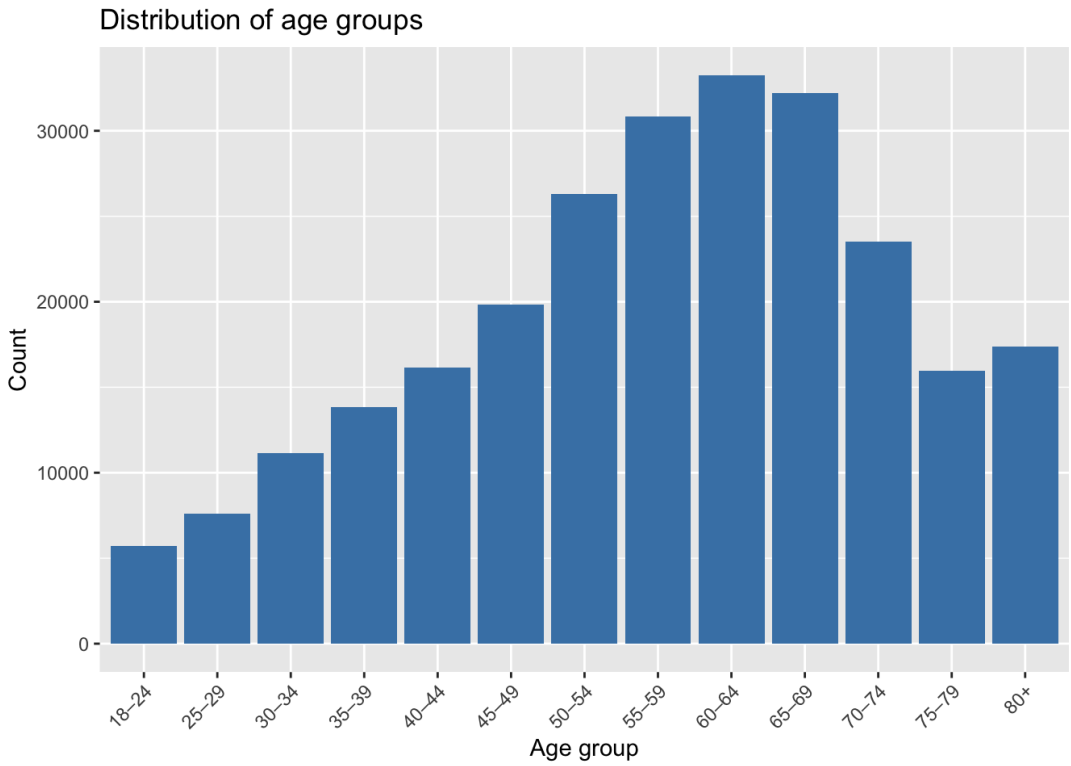


Hình 4: Phân bố của nhóm Age

Hình cho thấy phân bố mẫu khảo sát tập trung chủ yếu ở các nhóm tuổi trung niên và cao tuổi, với số lượng quan sát cao nhất ở các nhóm từ 55 đến 69 tuổi.

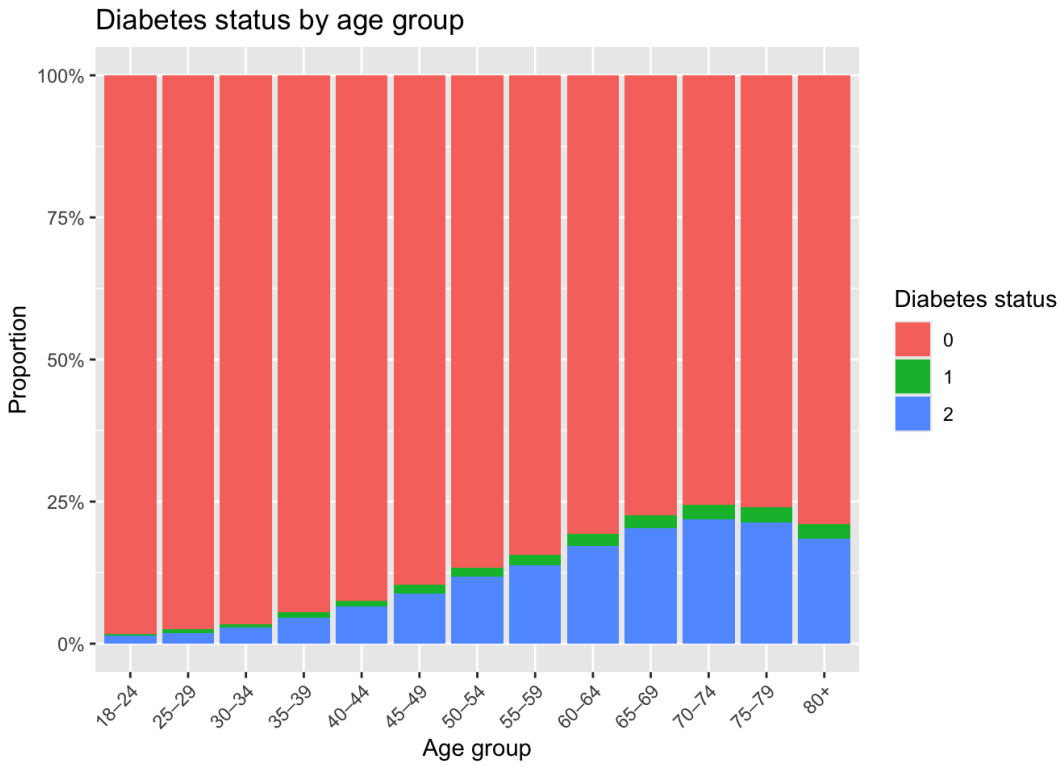


Hình 5: Biểu đồ Diabetes status theo nhóm tuổi

Hình minh họa mối quan hệ giữa nhóm tuổi và tình trạng tiểu đường. Có thể quan sát thấy tỷ lệ mắc tiểu đường tăng dần theo độ tuổi, đặc biệt rõ rệt từ nhóm tuổi 50 trở lên, trong khi tỷ lệ không mắc tiểu đường giảm dần. Kết quả này cho thấy tuổi là một yếu tố có liên quan mạnh đến nguy cơ mắc bệnh tiểu đường.

### 3.3 Phân bố biến BMI

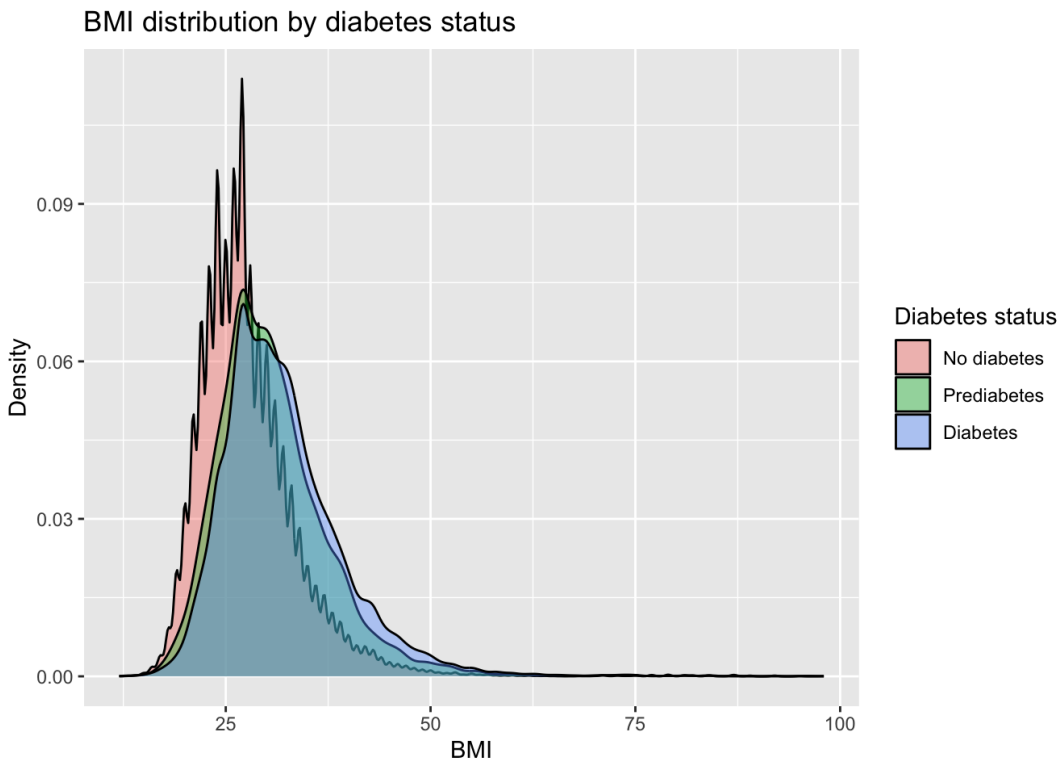


Hình 6: Phân bố BMI theo tình trạng tiểu đường

Khi phân nhóm theo tình trạng tiểu đường, phân bố BMI của nhóm mắc tiểu đường và tiền tiểu đường có xu hướng dịch sang phải so với nhóm không mắc. Điều này cho thấy các cá nhân có BMI cao thường xuất hiện nhiều hơn trong nhóm mắc bệnh, gợi ý mối liên hệ giữa chỉ số khối cơ thể và nguy cơ tiểu đường.

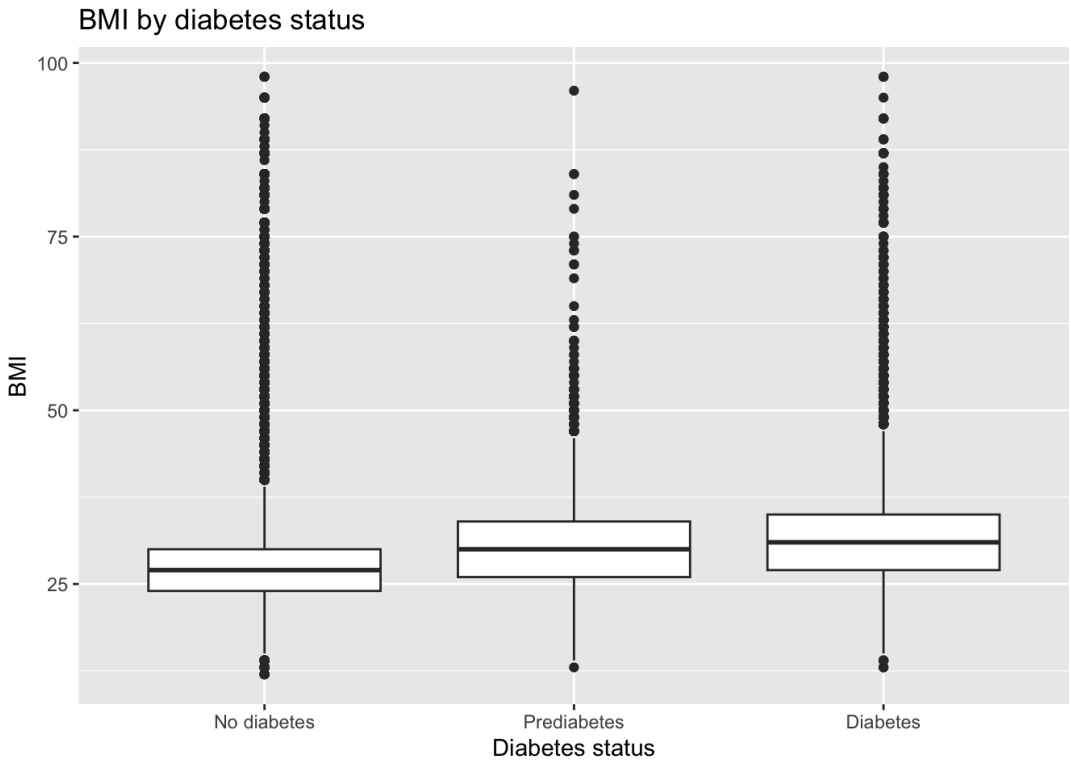


Hình 7: Boxplot BMI theo tình trạng tiểu đường

Biểu đồ hộp cho thấy trung vị BMI tăng dần từ nhóm không mắc tiểu đường, qua tiền tiểu đường đến nhóm mắc tiểu đường. Đồng thời, độ phân tán BMI ở nhóm mắc tiểu đường lớn hơn, phản ánh sự đa dạng về thể trạng trong nhóm này. Kết quả này củng cố vai trò của BMI như một yếu tố nguy cơ quan trọng liên quan đến bệnh tiểu đường.

### 3.4 Phân bố biến HighBP và biến HighChol

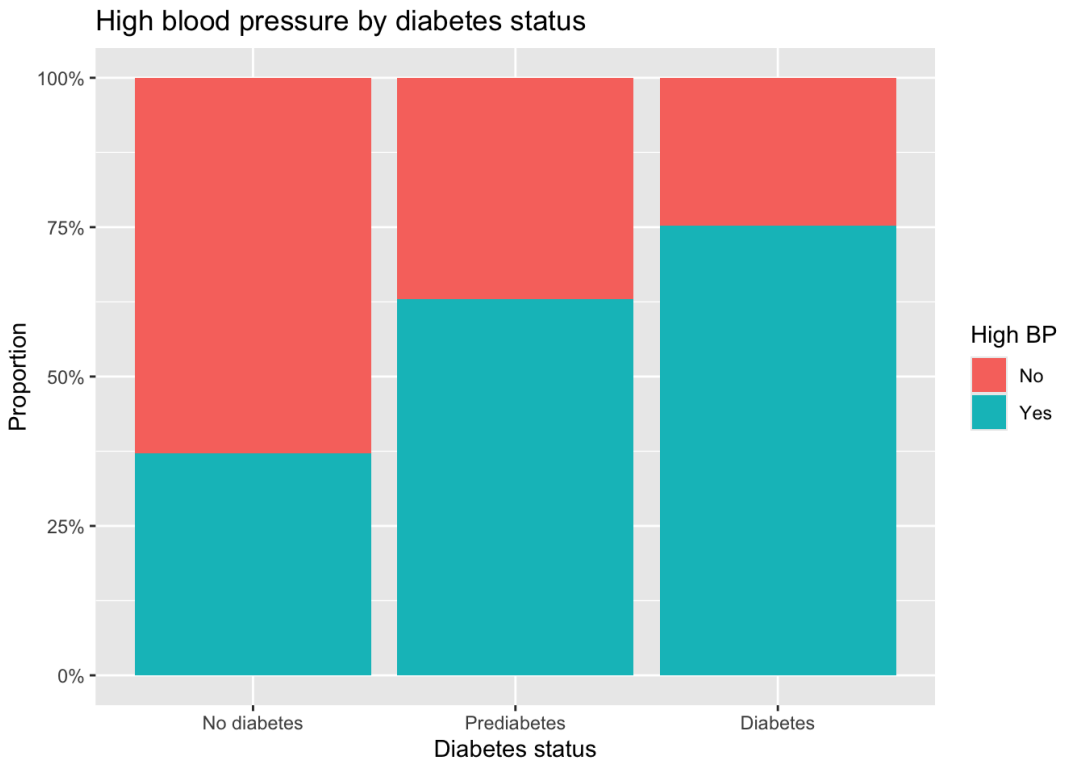


Hình 8: Phân bố biến cao huyết áp

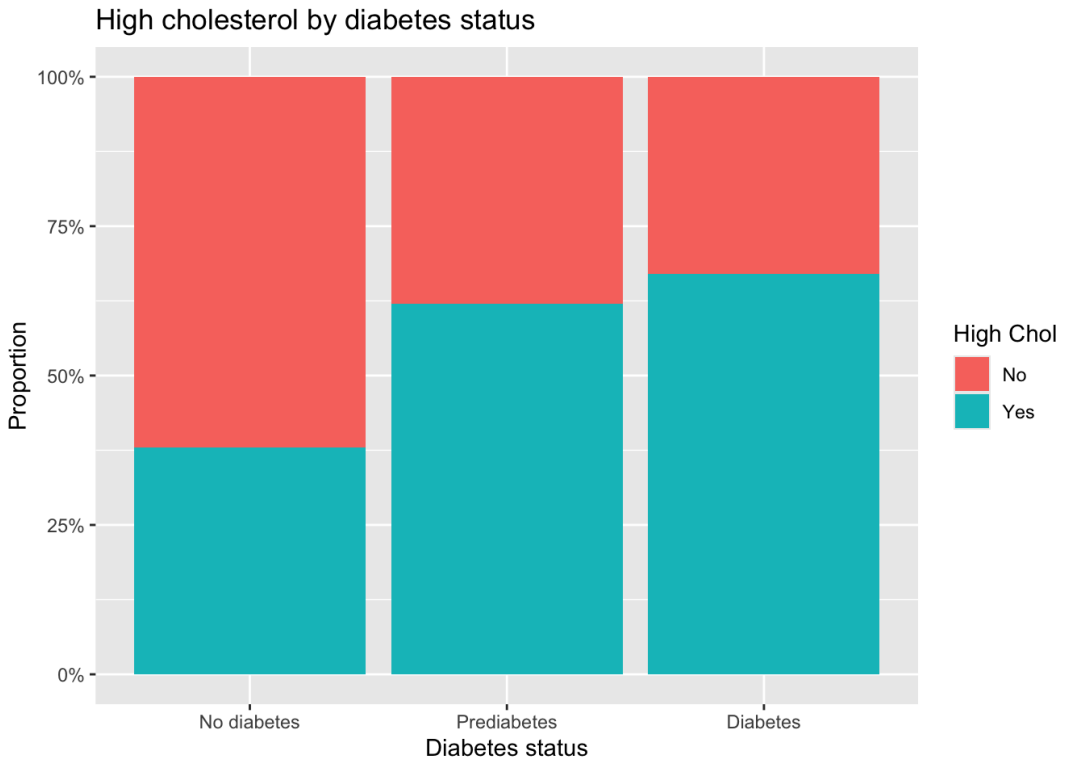


Hình 9: Phân bố biến cao cholesterol

Hai hình trên cho thấy sự khác biệt rõ rệt về tỷ lệ cao huyết áp và cao cholesterol giữa các nhóm tình trạng tiểu đường. Tỷ lệ mắc cao huyết áp và cao cholesterol tăng dần từ nhóm không tiểu đường sang nhóm tiền tiểu đường và đạt mức cao nhất ở nhóm tiểu đường. Điều này gợi ý mối liên hệ tiềm năng giữa các yếu tố nguy cơ tim mạch và tình trạng tiểu đường.

# 4 Phân tích mối liên hệ và kiểm định.

## 4.1 Phân tích Thống kê Mô tả.

Bảng thống kê mô tả cung cấp thông tin về quy mô mẫu, giá trị trung bình và độ lệch chuẩn của chỉ số BMI phân theo ba nhóm tình trạng sức khỏe: Không mắc bệnh tiểu đường, Tiền tiểu đường và Mắc bệnh tiểu đường.

| Diabetes_012 | n | mean_BMI | sd_BMI |
|---|---|---|---|
| No diabetes | 213703 | 27.74252 | 6.260993 |
| Prediabetes | 4631 | 30.72447 | 6.964898 |
| Diabetes | 35346 | 31.94401 | 7.363401 |

Bảng 1: Thống kê mô tả theo nhóm

Thông qua Thông kê mô tả trên ta có thể thấy. Có sự gia tăng rõ rệt về chỉ số BMI trung bình khi tình trạng bệnh tiến triển từ không mắc bệnh sang tiểu đường.

BMI trung bình của nhóm Tiền tiểu đường và Tiểu đường đều vượt ngưỡng 30.0, mức được phân loại là béo phì theo tiêu chuẩn quốc tế. Điều này phản ánh mối liên hệ chặt chẽ giữa tình trạng thừa cân, béo phì và rủi ro mắc bệnh chuyển hóa.

## 4.2 Kiểm định Giả thuyết Thống kê.

### 4.2.1 Kiểm định ANOVA một nhân tố.

Bảng 2: Kết quả phân tích phương sai (ANOVA)

| **Nguồn biến thiên** | **Df** | **Sum Sq** | **Mean Sq** | **F value** | **Pr(>F)** |
|---|---|---|---|---|---|
| Diabetes_012 | 2 | 561,268 | 280,634 | 6,768 | $< 2 \times 10^{-16}$ |
| Residuals | 253,677 | 10,518,121 | 41 | | |

*Ghi chú:* $^{***}p < 0.001$, $^{**}p < 0.01$, $^{*}p < 0.05$.

Kết quả phân tích phương sai một yếu tố cho thấy biến *Diabetes_012* có ảnh hưởng có ý nghĩa thống kê rất cao đến biến phụ thuộc đang xét. Giả thuyết không ($H_0$) bị bác

bỏ, cho thấy tồn tại sự khác biệt có ý nghĩa thống kê về giá trị trung bình của biến phụ thuộc giữa các nhóm tình trạng đái tháo đường.

Do kích thước mẫu lớn và phân bố BMI có thể lệch chuẩn, kết quả ANOVA được sử dụng mang tính tham khảo và được củng cố thêm bằng các kiểm định hoán vị không phụ thuộc giả định phân phối.

### 4.2.2 Kiểm định Fisher–Pitman.

Bảng 3: Kết quả kiểm định Fisher–Pitman Permutation Test cho BMI theo tình trạng đái tháo đường

| **Thống kê** | **Giá trị** |
|---|---|
| Biến phụ thuộc | BMI |
| Biến phân nhóm | Diabetes_012 (No diabetes, Prediabetes, Diabetes) |
| Thống kê $\chi^2$ | 12,851 |
| $p$-value | $< 2 \times 10^{-4}$ |

Kết quả kiểm định hoán vị Fisher–Pitman cho thấy sự khác biệt có ý nghĩa thống kê về chỉ số khối cơ thể giữa các nhóm tình trạng đái tháo đường. Điều này cho thấy phân phối BMI khác biệt đáng kể giữa các nhóm không mắc đái tháo đường, tiền đái tháo đường và đái tháo đường.

### 4.2.3 Permutation t-test với hiệu chỉnh Holm

Bảng 4: So sánh cặp hậu kiểm bằng Permutation t-test (hiệu chỉnh Holm)

| **Cặp so sánh** | $\boldsymbol{n_1}$ | $\boldsymbol{n_2}$ | $\boldsymbol{p}_{\text{adj}}$ | **Ý nghĩa** |
|---|---|---|---|---|
| No diabetes vs Prediabetes | 213,703 | 4,631 | $1.06 \times 10^{-212}$ | **** |
| No diabetes vs Diabetes | 213,703 | 35,346 | $< 10^{-300}$ | **** |
| Prediabetes vs Diabetes | 4,631 | 35,346 | $8.55 \times 10^{-34}$ | **** |

*Ghi chú:* Hiệu chỉnh đa so sánh bằng phương pháp Holm; **** $p < 0.0001$.

Phân tích hậu kiểm cho thấy BMI khác biệt có ý nghĩa thống kê rất cao giữa tất cả các cặp nhóm tình trạng đái tháo đường sau khi hiệu chỉnh Holm.

## 4.3 Phân tích tỷ lệ đái tháo đường theo nhóm tuổi và ước lượng bootstrap các yếu tố nguy cơ.

### 4.3.1 Phân tích tỷ lệ đái tháo đường theo nhóm tuổi.

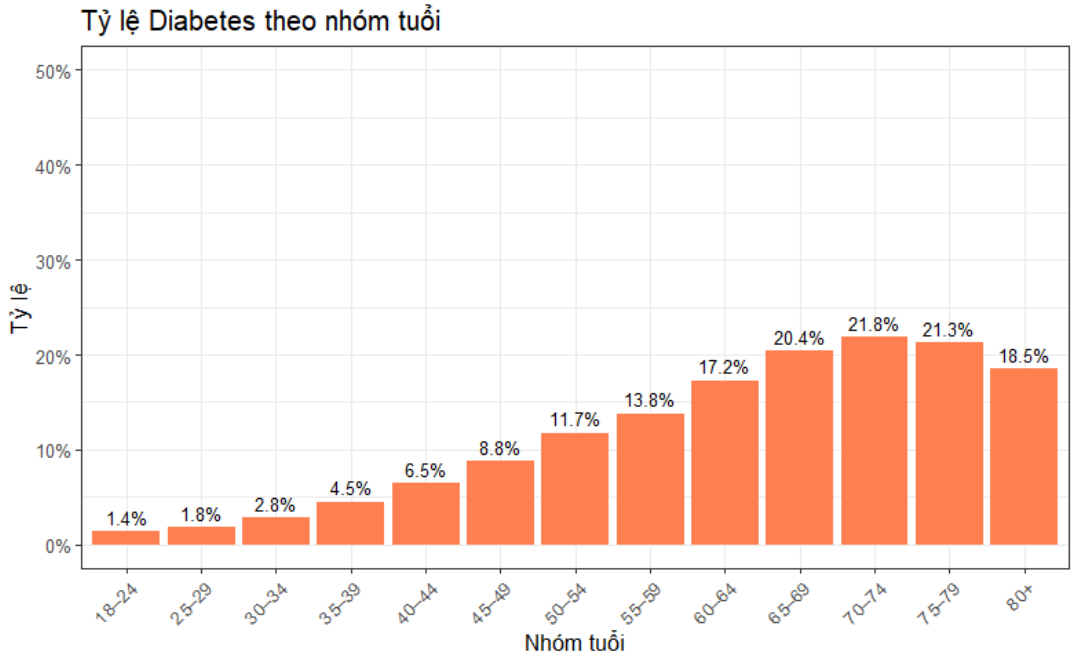


Hình 10: Tỷ lệ Diabetes theo nhóm tuổi

Hình trên cho thấy tỷ lệ đái tháo đường tăng rõ rệt theo nhóm tuổi. Ở các nhóm tuổi trẻ (18–34), tỷ lệ mắc đái tháo đường tương đối thấp (dưới 3%). Tỷ lệ này bắt đầu tăng nhanh từ nhóm tuổi 40–44 và đạt mức cao nhất ở các nhóm tuổi từ 65–74. Kết quả cho thấy tuổi là một yếu tố nguy cơ quan trọng liên quan đến đái tháo đường.

### 4.3.2 Ước lượng bootstrap các yếu tố nguy cơ.

Bootstrap cho phép đánh giá độ ổn định của ước lượng tỷ lệ yếu tố nguy cơ, bổ sung thông tin định lượng cho các kết luận dựa trên kiểm định giả thuyết.

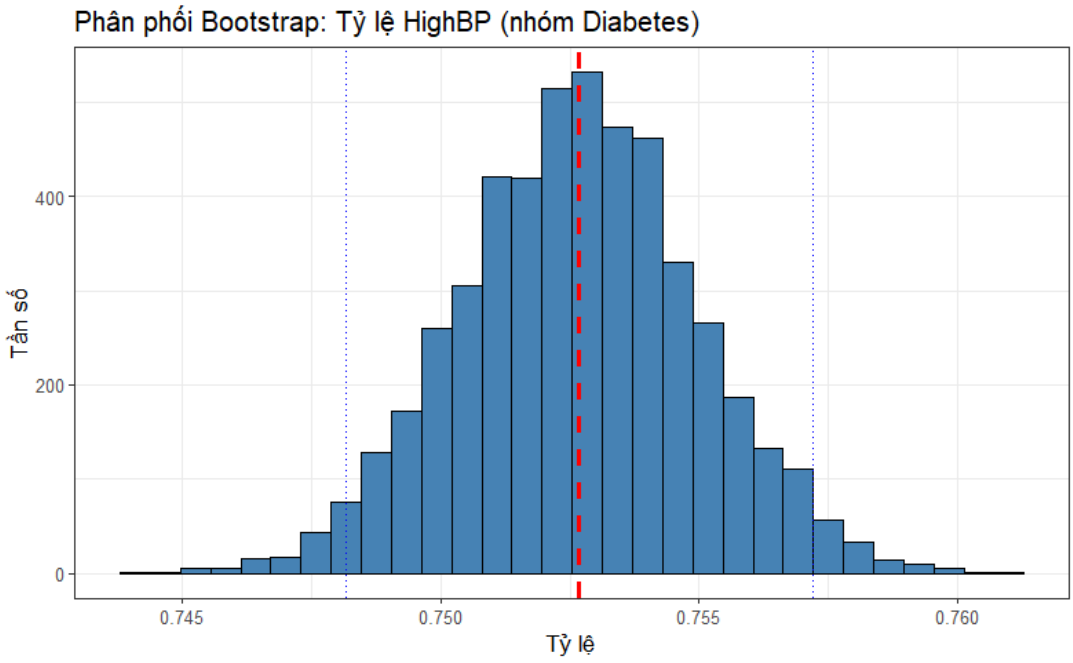


Hình 11: Phân phối Bootstrap tỷ lệ HighBP

Hình 11 trình bày phân phối bootstrap của tỷ lệ huyết áp cao trong nhóm đái tháo đường. Phân phối có dạng xấp xỉ đối xứng và tập trung quanh giá trị trung bình khoảng 0,75. Khoảng tin cậy bootstrap 95% hẹp cho thấy ước lượng tỷ lệ HighBP có độ ổn định cao và sai số lấy mẫu nhỏ.

## 4.4 Kết quả phân tích thống kê

### 4.4.1 Ước lượng tỷ lệ huyết áp cao bằng Bootstrap

Chúng tôi sử dụng phương pháp **bootstrap percentile** với 5,000 lần lặp để ước lượng khoảng tin cậy 95% cho tỷ lệ huyết áp cao (HighBP) theo từng nhóm tình trạng đái tháo đường.

- **Không mắc đái tháo đường**: Tỷ lệ HighBP = 0,371; KTC 95% = [0,369; 0,373].
- **Tiền đái tháo đường**: Tỷ lệ HighBP = 0,629; KTC 95% = [0,615; 0,642].
- **Đái tháo đường**: Tỷ lệ HighBP = 0,753; KTC 95% = [0,748; 0,757].

Kết quả cho thấy tỷ lệ huyết áp cao tăng rõ rệt theo mức độ nghiêm trọng của tình trạng đái tháo đường.

### 4.4.2 Mối liên hệ giữa Cholesterol cao và đái tháo đường

Kiểm định hoán vị được sử dụng để so sánh tỷ lệ cholesterol cao (HighChol) giữa nhóm đái tháo đường và nhóm không mắc đái tháo đường.

- Chênh lệch tỷ lệ quan sát: 0,291
- Giá trị $p < 0{,}001$

Ngoài ra, tỷ lệ HighChol trong nhóm đái tháo đường được ước lượng bằng bootstrap với KTC 95% là [0,665; 0,675], cho thấy sự khác biệt có ý nghĩa thống kê so với nhóm không mắc đái tháo đường.

### 4.4.3 Tình trạng hút thuốc và đái tháo đường

Kiểm định hoán vị được áp dụng để so sánh tỷ lệ hút thuốc giữa nhóm đái tháo đường và nhóm không mắc đái tháo đường.

- Chênh lệch tỷ lệ quan sát: 0,089
- Giá trị $p < 0{,}001$

Kết quả bootstrap cho thấy tỷ lệ hút thuốc trong nhóm đái tháo đường là 0,518, với KTC 95% = [0,513; 0,524], cho thấy sự khác biệt có ý nghĩa thống kê.

### 4.4.4 Thống kê mô tả theo nhóm tình trạng đái tháo đường

Bảng thống kê mô tả cho thấy BMI trung bình và tỷ lệ các yếu tố nguy cơ (huyết áp cao, cholesterol cao và hút thuốc) đều tăng dần từ nhóm không mắc đái tháo đường, nhóm tiền đái tháo đường đến nhóm đái tháo đường.

### 4.4.5 Tuổi và tỷ lệ đái tháo đường

Phân tích theo nhóm tuổi cho thấy tỷ lệ đái tháo đường tăng dần theo độ tuổi và đạt mức cao nhất ở các nhóm tuổi cao, cho thấy tuổi là một yếu tố nguy cơ quan trọng liên quan đến đái tháo đường.

## 4.5 Nhận xét và kết luận

Kết quả phân tích cho thấy mối liên hệ chặt chẽ giữa đái tháo đường và các yếu tố nguy cơ tim mạch cũng như lối sống. Nhóm đái tháo đường có BMI trung bình cao hơn đáng kể so với các nhóm còn lại. Đồng thời, tỷ lệ huyết áp cao, cholesterol cao và hút thuốc đều cao hơn rõ rệt trong nhóm này.

Các kiểm định hoán vị cho thấy mọi khác biệt đều có ý nghĩa thống kê với mức ý nghĩa $\alpha = 0{,}05$. Khoảng tin cậy bootstrap hẹp cho thấy các ước lượng có độ ổn định cao. Ngoài ra, tỷ lệ đái tháo đường tăng theo tuổi, nhấn mạnh vai trò của tuổi tác trong nguy cơ mắc bệnh.

Những kết quả này cho thấy sự cần thiết của các biện pháp can thiệp sớm nhằm kiểm soát BMI, huyết áp, cholesterol và lối sống, đặc biệt ở các nhóm có nguy cơ cao và nhóm tiền đái tháo đường.

# 5 Hồi quy và tiên đoán.

## 5.1 Kết quả mô hình GLM (Logistic Regression)

### 5.1.1 Phân bố biến phụ thuộc và cân bằng dữ liệu

Phân bố ban đầu của biến phụ thuộc cho thấy dữ liệu bị mất cân bằng nghiêm trọng, trong đó nhóm không mắc tiểu đường chiếm tỷ lệ áp đảo so với nhóm mắc tiểu đường.

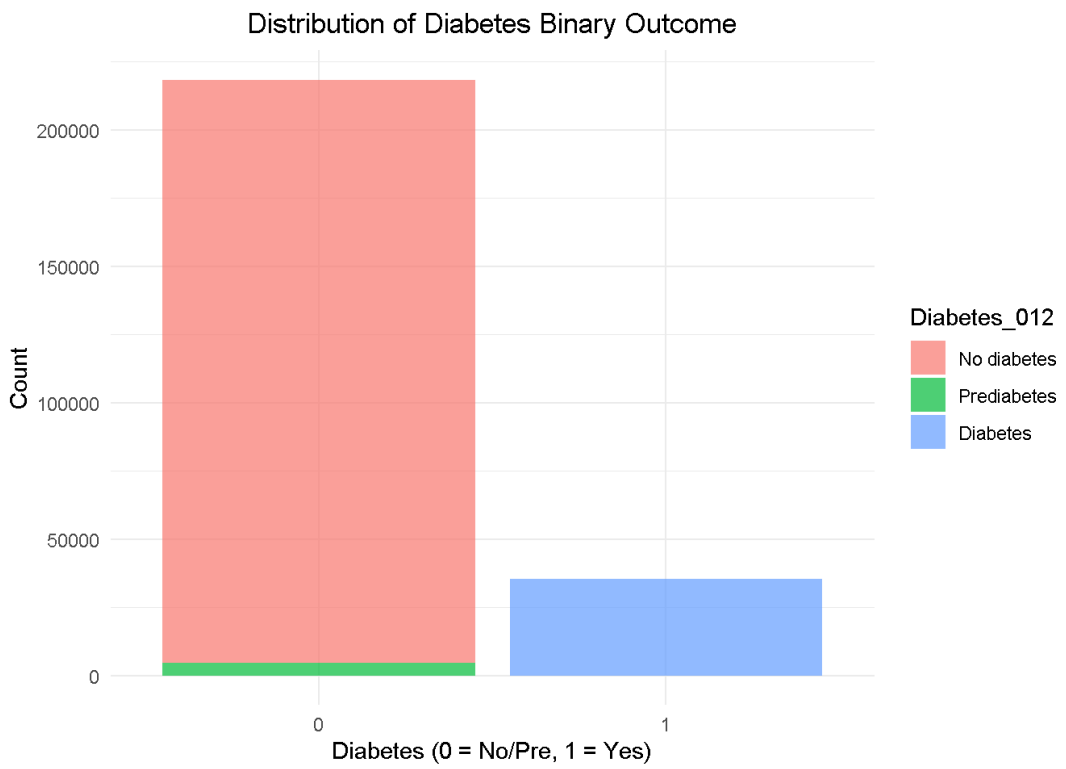


Để khắc phục hiện tượng này, phương pháp upsampling được áp dụng nhằm cân bằng số lượng quan sát giữa hai lớp.

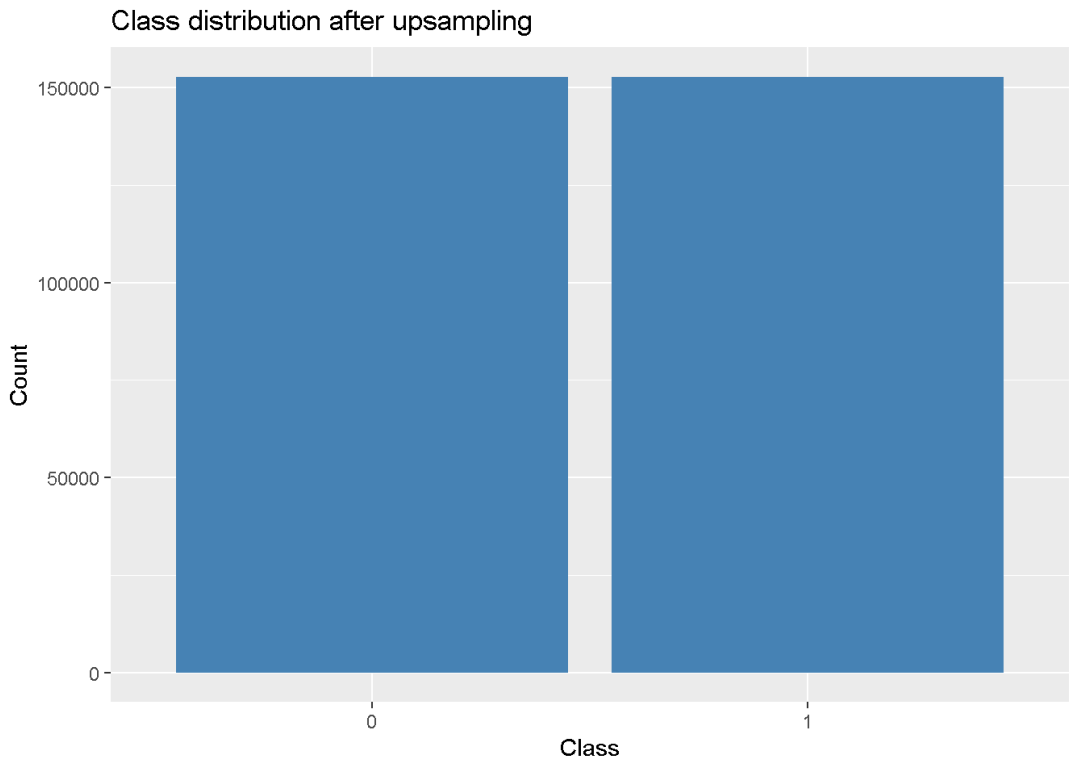


Sau khi cân bằng dữ liệu, số lượng quan sát của hai lớp gần tương đương nhau, giúp mô hình hồi quy logistic học được đặc trưng của cả hai nhóm và giảm thiên lệch trong quá trình huấn luyện.

### 5.1.2 Kết quả ước lượng mô hình

Mô hình hồi quy logistic được ước lượng với biến phụ thuộc là tình trạng mắc tiểu đường (nhị phân), sử dụng các biến giải thích gồm tuổi, chỉ số BMI, huyết áp cao, cholesterol cao, hút thuốc, hoạt động thể chất, giới tính, thu nhập và tình trạng sức khỏe tổng quát.

```
##
## Call:
## glm(formula = Diabetes_binary ~ Age + BMI + HighBP + HighChol +
##     Smoker + PhysActivity + Sex + Income + GenHlth, family = binomial,
##     data = train_data_balanced)
##
## Coefficients:
##                Estimate Std. Error  z value Pr(>|z|)
## (Intercept)  -5.7994786  0.0374517 -154.852  < 2e-16 ***
## Age           0.1634507  0.0017539   93.192  < 2e-16 ***
## BMI           0.0754757  0.0007383  102.228  < 2e-16 ***
## HighBPYes     0.7519125  0.0093620   80.316  < 2e-16 ***
## HighCholYes   0.6066994  0.0089478   67.804  < 2e-16 ***
## SmokerYes    -0.0271305  0.0088693   -3.059  0.00222 **
## PhysActivity -0.0471343  0.0098924   -4.765 1.89e-06 ***
## Sex           0.3130909  0.0089599   34.944  < 2e-16 ***
## Income       -0.0701599  0.0022045  -31.825  < 2e-16 ***
## GenHlth       0.5875375  0.0047464  123.785  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 423746  on 305667  degrees of freedom
## Residual deviance: 318105  on 305658  degrees of freedom
## AIC: 318125
##
## Number of Fisher Scoring iterations: 4
```

Kết quả cho thấy tất cả các biến trong mô hình đều có ý nghĩa thống kê ở mức 5%. Trong đó, các biến như tuổi, BMI, huyết áp cao, cholesterol cao và tình trạng sức khỏe tổng quát có mức ý nghĩa rất cao với *p-value* nhỏ hơn $2 \times 10^{-16}$.

### 5.1.3 Đánh giá đa cộng tuyến bằng chỉ số VIF

```
##          Age          BMI       HighBP     HighChol       Smoker PhysActivity
##     1.133034     1.088375     1.118155     1.050432     1.041619     1.072715
##          Sex       Income      GenHlth
##     1.060108     1.166336     1.169742
```

Để kiểm tra hiện tượng đa cộng tuyến giữa các biến độc lập trong mô hình hồi quy Logistic, chỉ số hệ số phóng đại phương sai (Variance Inflation Factor – VIF) đã được sử dụng. Kết quả cho thấy các biến giải thích đều có giá trị VIF dao động trong khoảng từ 1.04 đến 1.17.

Theo ngưỡng đánh giá thông thường (VIF $< 5$), các giá trị này là rất thấp và không cho thấy dấu hiệu đa cộng tuyến nghiêm trọng. Ngay cả các biến có VIF lớn nhất như *Income* và *GenHlth* cũng vẫn nằm trong giới hạn cho phép và không ảnh hưởng đáng kể đến độ ổn định của mô hình.

Do đó, có thể kết luận rằng mô hình không gặp vấn đề đa cộng tuyến, và các hệ số hồi quy được ước lượng là đáng tin cậy cho mục tiêu dự đoán xác suất mắc bệnh tiểu đường.

### 5.1.4 Tỷ số odds (Odds Ratio)

```
##  (Intercept)          Age          BMI    HighBPYes  HighCholYes    SmokerYes
##  0.003029134  1.177567346  1.078396984  2.121052567  1.834366824  0.973234262
## PhysActivity          Sex       Income      GenHlth
##  0.953959278  1.367645827  0.932244732  1.799551577
```

Các hệ số hồi quy được chuyển đổi sang dạng tỷ số odds để thuận tiện cho việc diễn giải. Kết quả cho thấy:

- Huyết áp cao làm tăng odds mắc tiểu đường hơn 2 lần.
- Cholesterol cao làm tăng odds mắc tiểu đường khoảng 1.83 lần.
- Tình trạng sức khỏe tổng quát kém làm tăng odds mắc tiểu đường khoảng 1.80 lần.
- Tuổi và BMI cũng làm tăng odds mắc tiểu đường, tuy nhiên mức tăng là vừa phải.
- Thu nhập cao và hoạt động thể chất có tác dụng bảo vệ, làm giảm odds mắc tiểu đường.

### 5.1.5 Kết quả phân loại và tiên đoán

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction     0     1
##          0 47177  2508
##          1 18323  8095
##
##                Accuracy : 0.7263
##                  95% CI : (0.7231, 0.7294)
##     No Information Rate : 0.8607
##     P-Value [Acc > NIR] : 1
##
##                   Kappa : 0.2977
##
##  Mcnemar's Test P-Value : <2e-16
##
##             Sensitivity : 0.7203
##             Specificity : 0.7635
##          Pos Pred Value : 0.9495
##          Neg Pred Value : 0.3064
##              Prevalence : 0.8607
##          Detection Rate : 0.6199
##    Detection Prevalence : 0.6529
##       Balanced Accuracy : 0.7419
##
##        'Positive' Class : 0
##
```

Hiệu quả phân loại của mô hình được đánh giá thông qua ma trận nhầm lẫn và các chỉ số liên quan. Kết quả cho thấy:

- Độ chính xác (Accuracy) đạt khoảng 72.6%.
- Độ nhạy (Sensitivity) đạt khoảng 72.0%.
- Độ đặc hiệu (Specificity) đạt khoảng 76.4%.

- Balanced Accuracy đạt khoảng 74.2%.

Các chỉ số trên cho thấy mô hình có khả năng phân loại tương đối tốt giữa hai nhóm mắc và không mắc tiểu đường sau khi đã cân bằng dữ liệu.

### 5.1.6 Nhận xét

Mô hình GLM logistic cho kết quả ổn định với các biến giải thích đều có ý nghĩa thống kê. Việc cân bằng dữ liệu bằng phương pháp upsampling giúp cải thiện khả năng phát hiện nhóm mắc tiểu đường. Tuy nhiên, mô hình vẫn tồn tại sai số phân loại, cho thấy cần xem xét bổ sung thêm biến giải thích hoặc sử dụng các phương pháp mô hình hóa nâng cao hơn trong các nghiên cứu tiếp theo.

## 5.2 Kết quả mô hình GAM (Generalized Additive Model)

## 5.3 Kết quả ước lượng mô hình

Mô hình GAM với phân phối nhị thức và hàm liên kết logit được sử dụng nhằm nắm bắt các mối quan hệ phi tuyến giữa biến phụ thuộc và các biến giải thích liên tục. Trong mô hình, tuổi và chỉ số BMI được mô hình hóa dưới dạng hàm trơn, trong khi các biến còn lại được giữ ở dạng tham số.

```
##
## Family: binomial
## Link function: logit
##
## Formula:
## Diabetes_binary ~ s(Age) + s(BMI) + HighBP + HighChol + Smoker +
##     PhysActivity + Sex + Income + GenHlth
##
## Parametric coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -2.036297   0.023789 -85.598  < 2e-16 ***
## HighBPYes     0.704564   0.009443  74.611  < 2e-16 ***
## HighCholYes   0.566484   0.009059  62.534  < 2e-16 ***
## SmokerYes    -0.039457   0.008964  -4.402 1.07e-05 ***
## PhysActivity -0.043720   0.009966  -4.387 1.15e-05 ***
## Sex           0.290144   0.009103  31.872  < 2e-16 ***
## Income       -0.081115   0.002243 -36.170  < 2e-16 ***
## GenHlth       0.585028   0.004802 121.841  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Approximate significance of smooth terms:
##          edf Ref.df Chi.sq p-value
## s(Age) 8.723  8.970   9546  <2e-16 ***
## s(BMI) 8.519  8.891  13197  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## R-sq.(adj) =  0.316   Deviance explained = 25.9%
## UBRE = 0.027169  Scale est. = 1         n = 305668
```

Kết quả ước lượng cho thấy tất cả các hệ số tham số đều có ý nghĩa thống kê ở mức 5%. Các biến huyết áp cao, cholesterol cao, giới tính và tình trạng sức khỏe tổng quát có tác động dương rõ rệt lên xác suất mắc tiểu đường. Ngược lại, hoạt động thể chất và thu nhập có tác động làm giảm xác suất mắc tiểu đường.

### 5.3.1 Diễn giải các hệ số tham số

```
##      HighBP  HighChol      Smoker PhysActivity      Sex      Income  GenHlth
## 1 0.7045638 0.5664845 -0.03945682   0.00000000 0.000000 -0.24334492 2.925141
## 2 0.0000000 0.0000000 -0.03945682  -0.04372027 0.000000 -0.08111497 1.755085
## 3 0.7045638 0.0000000  0.00000000  -0.04372027 0.000000 -0.48668984 1.170056
## 4 0.7045638 0.5664845 -0.03945682  -0.04372027 0.290144 -0.64891979 1.170056
## 5 0.7045638 0.5664845 -0.03945682  -0.04372027 0.000000 -0.32445990 1.755085
## 6 0.0000000 0.0000000  0.00000000   0.00000000 0.290144 -0.24334492 1.170056
##        s(Age)     s(BMI)
## 1  0.16030707  0.8486144
## 2 -0.20613005 -0.4440284
## 3  0.50039534 -0.2066834
## 4  0.39265857 -0.4440284
## 5  0.50039534 -0.4440284
## 6 -0.04938711 -0.5614771
```

Hệ số của biến huyết áp cao và cholesterol cao mang giá trị dương và có ý nghĩa thống kê rất cao, cho thấy các yếu tố này làm tăng đáng kể nguy cơ mắc tiểu đường. Biến tình trạng sức khỏe tổng quát có hệ số lớn nhất trong nhóm biến tham số, phản ánh mức độ ảnh hưởng mạnh đến xác suất mắc bệnh.

Biến hút thuốc và hoạt động thể chất có hệ số âm với mức ý nghĩa thống kê cao, cho thấy vai trò bảo vệ của lối sống lành mạnh. Thu nhập có tác động âm và có ý nghĩa thống kê, cho thấy nhóm thu nhập cao có xác suất mắc tiểu đường thấp hơn.

### 5.3.2 Đánh giá độ phù hợp của mô hình

Mô hình GAM giải thích khoảng 25.9% độ lệch (deviance explained) của dữ liệu, với hệ số $R^2$ hiệu chỉnh đạt khoảng 0.316. So với mô hình hồi quy logistic tuyến tính, mô hình GAM cho thấy khả năng mô tả dữ liệu tốt hơn nhờ việc nắm bắt các mối quan hệ phi tuyến.

Giá trị UBRE ở mức thấp cho thấy mô hình có độ ổn định tốt và phù hợp với dữ liệu huấn luyện.

### 5.3.3 Minh họa trực quan các hiệu ứng

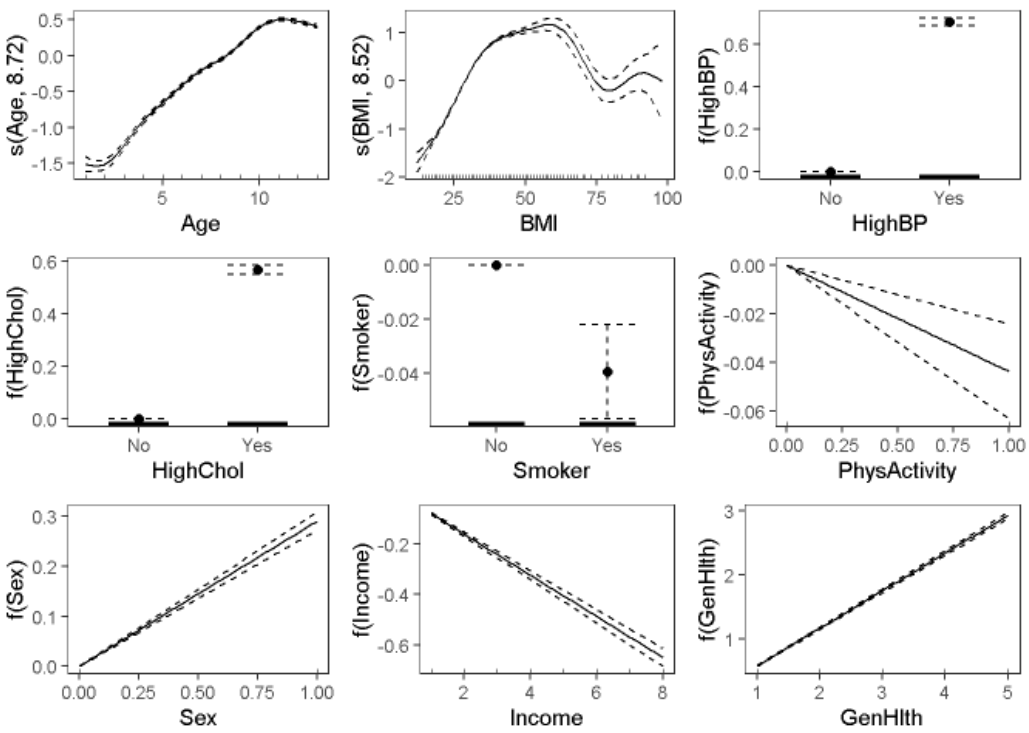


Các đồ thị thành phần trơn cho thấy hình dạng mối quan hệ phi tuyến giữa tuổi, BMI và xác suất mắc tiểu đường. Đối với các biến nhị phân như huyết áp cao và cholesterol cao, hiệu ứng được thể hiện rõ ràng qua sự khác biệt giữa hai nhóm. Các biến lối sống như hút thuốc và hoạt động thể chất thể hiện xu hướng làm giảm nguy cơ mắc tiểu đường.

### 5.3.4 Nhận xét

Mô hình GAM cho kết quả nhất quán với mô hình hồi quy logistic nhưng cung cấp cái nhìn chi tiết hơn về các mối quan hệ phi tuyến. Đặc biệt, việc mô hình hóa tuổi và BMI dưới dạng hàm trơn giúp cải thiện khả năng giải thích và dự đoán của mô hình. Tuy nhiên, mô hình vẫn có thể được cải thiện bằng cách bổ sung thêm các biến giải thích hoặc xem xét các cấu trúc trơn phức tạp hơn.

## 5.4 Kết quả mô hình Logistic LASSO

### 5.4.1 Lựa chọn tham số phạt

Mô hình Logistic LASSO được ước lượng với tham số phạt $\lambda$ được lựa chọn thông qua phương pháp cross-validation. Giá trị $\lambda$ tối ưu được xác định tại điểm làm tối thiểu hóa binomial deviance.

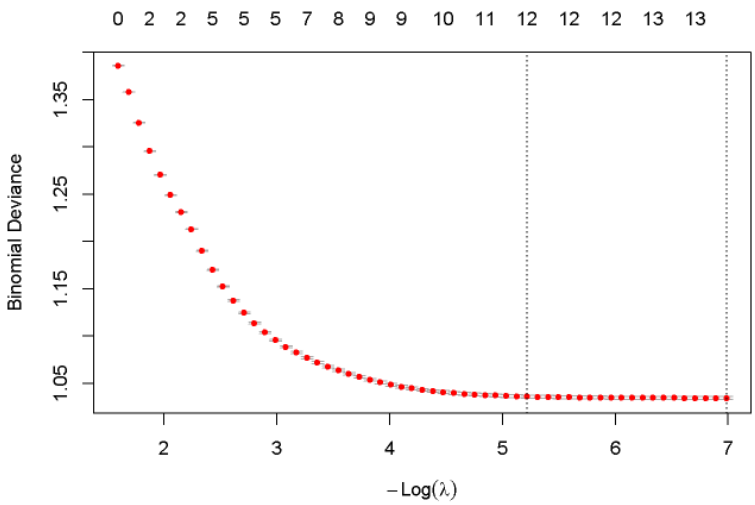


```
best_lambda_lasso <- cv_lasso$lambda.min
best_lambda_lasso
```

```
## [1] 0.0009237724
```

Kết quả cho thấy giá trị $\lambda$ tối ưu vào khoảng 0.0009, tại đó mô hình đạt được sự cân bằng giữa độ phù hợp và mức độ đơn giản của mô hình. Đường cong cross-validation cho thấy binomial deviance giảm mạnh khi $\lambda$ tăng từ nhỏ đến trung bình và sau đó ổn định, phản ánh hiệu quả của cơ chế regularization.

### 5.4.2 Kết quả chọn lọc biến

Mô hình LASSO thực hiện đồng thời việc ước lượng hệ số và chọn lọc biến.

```
## 14 x 1 sparse Matrix of class "dgCMatrix"
##                              s0
## (Intercept)          -6.63925214
## HighBPYes             0.71883458
## HighCholYes           0.57374800
## CholCheck             1.23436193
## BMI                   0.07423811
## SmokerYes            -0.02216373
## Stroke                0.16316772
## HeartDiseaseorAttack  0.25331693
## PhysActivity         -0.03677461
## Sex                   0.28384785
## Age                   0.15104046
## Education            -0.04198519
## Income               -0.05971558
## GenHlth               0.55865559
```

Kết quả cho thấy 13 biến giải thích được giữ lại trong mô hình với hệ số khác không.

Các biến có hệ số dương bao gồm huyết áp cao, cholesterol cao, kiểm tra cholesterol, BMI, tiền sử đột quỵ, bệnh tim, giới tính, tuổi và tình trạng sức khỏe tổng quát, cho thấy các yếu tố này làm tăng xác suất mắc tiểu đường.

Ngược lại, các biến hút thuốc, hoạt động thể chất, trình độ học vấn và thu nhập có hệ số âm, cho thấy vai trò bảo vệ của lối sống và điều kiện kinh tế – xã hội.

### 5.4.3 Đặc điểm của mô hình

So với mô hình hồi quy logistic thông thường, Logistic LASSO cho phép giảm hiện tượng đa cộng tuyến và hạn chế overfitting thông qua việc co rút các hệ số hồi quy. Mô hình đạt được cấu trúc gọn nhẹ hơn trong khi vẫn giữ lại các biến có ảnh hưởng quan trọng.

### 5.4.4 Đánh giá khả năng tiên đoán

Khả năng phân biệt của mô hình Logistic LASSO được đánh giá thông qua đường cong ROC trên tập dữ liệu kiểm tra. Giá trị diện tích dưới đường cong (AUC) đạt khoảng 0.823, cho thấy mô hình có khả năng phân biệt tốt giữa hai nhóm mắc và không mắc tiểu đường.

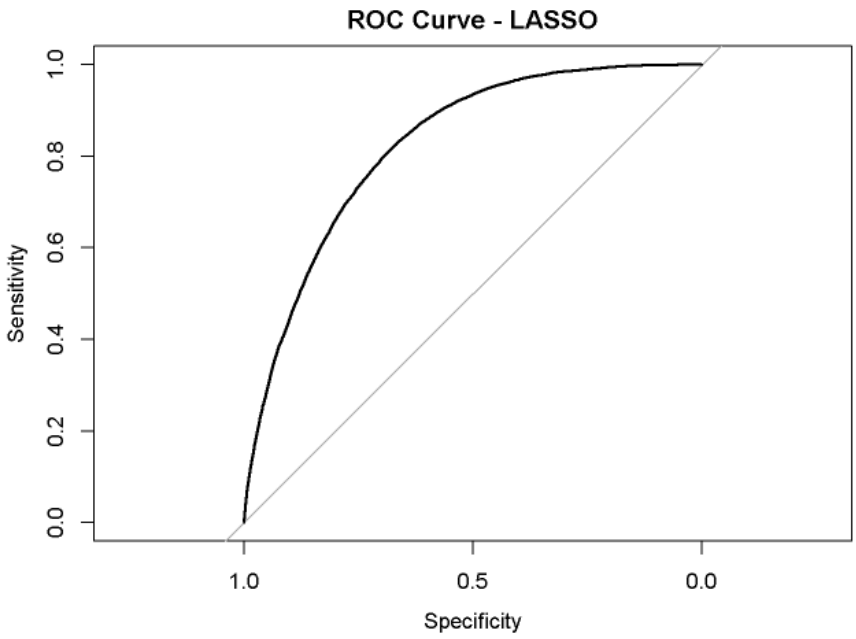


Đường cong ROC của mô hình nằm rõ rệt phía trên đường chéo tham chiếu, phản ánh sự đánh đổi hợp lý giữa độ nhạy và độ đặc hiệu ở nhiều ngưỡng phân loại khác nhau.

### 5.4.5 Nhận xét

Mô hình Logistic LASSO cho kết quả ổn định với khả năng tiên đoán tốt và cấu trúc mô hình gọn nhẹ. Việc chọn lọc biến tự động giúp mô hình dễ diễn giải hơn so với mô hình logistic đầy đủ, đồng thời duy trì hiệu quả phân loại tương đương với các mô hình phức tạp hơn.

## Tài liệu